

****Nome:** RICARDO FERNANDES DE ALMEIDA**

****Turma:** 2025.2**

****Especialização Cesar - Engenharia e Análise de DADOS****

****Disciplina: RNA e Deep Learning****

****Atividade Aula 4.3**

1. Acesse a página <http://playground.tensorflow.org> e utilizando apenas 2 entradas (x_1 e x_2), procure variar os diversos parâmetros:

- número de camadas
- número de neurônios em cada camada
- tipo de ativação
- learning rate
- fator de regularização

Resolva para o dataset "Spiral".

Coloque no pdf uma screenshot da tela com sua solução e comente sobre o que aprendeu nesse exercício (qual o impacto do número de camadas, neurônios em cada camada, ativação, learning rate e regularização).

Test Loss: Abaixo de 0.1



Exercício - TensorFlow Playground: Dataset Spiral

Configuração utilizada: apenas X1 e X2 como entradas, 2 camadas ocultas com 7 neurônios cada, ativação ReLU, learning rate 0.03, batch size 10.

Resultado: Test loss 0.044 / Training loss 0.009 na época 1.146.

O que aprendi:

Número de camadas

O dataset espiral é um dos mais complexos do Playground. Com 1 camada oculta a rede não consegue resolver. Com 2 camadas já é possível, pois cada camada adicional permite compor representações mais abstratas. É a prova prática de por que redes profundas existem.

Número de neurônios por camada

Com poucos neurônios, como 2 ou 3, a rede tende a subajustar os dados (*underfitting*), pois possui baixa capacidade de representar padrões complexos. Nesse caso, a fronteira de decisão fica **pouco refinada**. Com muitos neurônios, por exemplo 8 ou mais, a rede passa a ter capacidade suficiente para aprender melhor os padrões, mas pode começar a memorizar o conjunto de treino se não houver regularização, o que aparece quando a *test loss* fica maior que a *training loss*.

Tipo de ativação

ReLU (usado no experimento): converge rápido, fronteiras nitidas.

Sigmoid/Tanh: convergência mais lenta, mas as vezes fronteiras mais suaves.

Linear: falha completamente no espiral, só traça hiperplanos.

Learning rate

Muito alto (ex: 1.0): a perda oscila e nunca converge.

Muito baixo (ex: 0.001): converge, mas lentíssimo (precisa de muito mais épocas).

O valor 0.03 é um bom equilíbrio para SGD com mini-batch.

Regularização

Sem regularização: o modelo pode decorar o treino (training loss << test loss).

L2 (Ridge) suaviza os pesos e reduz overfitting, especialmente com redes grandes.

No espiral com apenas 2 entradas e rede moderada, o impacto é menor, mas fica evidente ao aumentar muito o número de neurônios.

Conclusão geral

O dataset espiral mostra que problemas com fronteiras muito complexas exigem profundidade (camadas) + capacidade (neurônios) + não-linearidade (ativação). Nenhum desses três elementos sozinhos resolvem, os três juntos sim.

